

逐步二次规划 SQP 算法

姓名：陈泽豪 学号：SA22001009

2023 年 4 月 29 日

摘要

本报告将会针对逐步二次规划 SQP 算法，给出其具体实现的理论描述以及实验结果展示，最后给出本次 SQP 算法实验的收获以及总结。

一、SQP 算法介绍

1.1 对 SQP 算法的简要流程描述

SQP (sequential quadratic programming) 算法, 即逐步二次规划算法, 是一类典型的用来处理非线性约束最优化问题的方法。我们可以从等式约束出发推广到不等式约束, 对于如下的非线性等式约束最优化问题:

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & c(x) = 0 \end{aligned} \quad (1)$$

其中 $c(x) = (c_1(x), c_2(x), \dots, c_m(x))^T$ 为约束函数向量。那么写出它的 (K-T) 条件如下所示:

$$G(x) = \begin{cases} L(x, \lambda) = \nabla f(x) - A(x)^T \lambda = 0 \\ c(x) = 0 \\ A(x) = (\nabla c(x)) = (\nabla c_1(x), \dots, \nabla c_m(x))^T \in \mathbf{R}^{m \times n} \end{cases} \quad (2)$$

其中 $\lambda \in \mathbf{R}^m$. 那么利用 *Newton - Raphson* 迭代求解 (2) 对应的等式组零点便有:

$$\begin{aligned} J(G(x)) \begin{pmatrix} \delta_x \\ \delta_\lambda \end{pmatrix} &= -G(x) \\ \begin{pmatrix} W(x, \lambda) & -A(x)^T \\ -A(x) & 0 \end{pmatrix} \begin{pmatrix} \delta_x \\ \delta_\lambda \end{pmatrix} &= - \begin{pmatrix} \nabla f(x) - A(x)^T \lambda \\ -c(x) \end{pmatrix} \end{aligned} \quad (3)$$

其中有 $W(x, \lambda) = \nabla^2 L(x, \lambda) = \nabla^2 f(x) - \sum_{i=1}^m \lambda_i \nabla^2 c_i(x)$ 。在求解出 δ_x, δ_λ 之后更新给的初值 x, λ , 并重新进行上述方程组的计算, 最终利用价值函数 $\psi = \|\nabla f(x) - A(x)^T \lambda\|^2 + \|c(x)\|^2$ 作为终止判定条件。另一种思路: 我们将 (3) 中的矩阵等式进行改写, 可以变成如下的形式:

$$\begin{cases} W(x, \lambda) \delta_x + \nabla f(x) = A(x)^T (\lambda + \delta_\lambda) \\ c(x) + A(x)^T \delta_\lambda = 0 \end{cases} \quad (4)$$

而我们可以进一步发现有此时的 δ_{x_k} 就是如下二次规划问题的 (K-T) 点:

$$\begin{aligned} \min_d \quad & \frac{1}{2} d^T W(x^{(k)}, \lambda^{(k)}) d + \nabla f(x^{(k)})^T d \\ \text{s.t.} \quad & c(x^{(k)}) + A(x^{(k)})^T d = 0 \end{aligned} \quad (5)$$

求解这个 QP 问题 dual problem, 便有解 $d^{(k)}$ 满足 $d^{(k)} = \delta_{x^{(k)}}$, 求解出来的 lagrange multipliers $\bar{\lambda}^{(k)}$ 满足 $\bar{\lambda}^{(k)} = \lambda^{(k)} + \delta_{\lambda^{(k)}}$ 。因此与上面类似的流程, 每次都去更新 x, λ , 并用一个价值函数进行终止判定以及步长调整。

在有了上面的等式约束 SQP 问题的铺垫之后, 对于下面的不等式约束优化问题:

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, i \in \epsilon = \{1, \dots, m_e\}, \\ & c_i(x) \geq 0, i \in I = \{m_e + 1, \dots, m\}. \end{aligned} \quad (6)$$

便也是同样的处理思路，它的 lagrange 函数如下：

$$L(x, \lambda) = f(x) - \left(\lambda_1, \dots, \lambda_{m_e}, \lambda_{m_e+1}, \dots, \lambda_m \right) \begin{pmatrix} c_1(x) \\ \dots \\ c_{m_e}(x) \\ c_{m_e+1}(x) \\ \dots \\ c_m(x) \end{pmatrix} = f(x) - \lambda^T c(x) \quad (7)$$

此时矩阵等式 (4) 由于不等式约束的加入会发生变化，如下所示：

$$\begin{cases} W(x^{(k)}, \lambda^{(k)})d^{(k)} + \nabla f(x^{(k)}) = A(x^{(k)})^T \bar{\lambda}^{(k)}. \\ \bar{\lambda}_i^{(k)} \geq 0, i \in I. \\ c(x^{(k)}) + A(x^{(k)})^T d^{(k)} = 0. \\ d^{(k)} = \delta_{x^{(k)}}. \\ \bar{\lambda}^{(k)} = \lambda^{(k)} + \delta_{\lambda^{(k)}}. \end{cases} \quad (8)$$

而它就相当于求解如下的二次规划问题：

$$\begin{aligned} \min_d \quad & \frac{1}{2} d^T W(x^{(k)}, \lambda^{(k)})d + \nabla f(x^{(k)})^T d \\ \text{s.t.} \quad & c_i(x^{(k)}) + a_i(x^{(k)})d = 0, i \in \epsilon \\ & c_i(x^{(k)}) + a_i(x^{(k)})d \geq 0, i \in I \end{aligned} \quad (9)$$

其中有 $A(x) = (\nabla c_1(x), \dots, \nabla c_m(x))^T = (a_1(x), \dots, a_m(x))^T$ ，同样的，(9) 中解出来的解 $d^{(k)}$ 满足 $d^{(k)} = \delta_{x^{(k)}}$ ，求解出来的 lagrange multipliers $\bar{\lambda}^{(k)}$ 满足 $\bar{\lambda}^{(k)} = \lambda^{(k)} + \delta_{\lambda^{(k)}}$ 。

另一个与等式约束 SQP 不同的地方是，此时我们使用罚函数 $P(x, \sigma)$ 进行步长的调整，对于不等式约束问题，我们不希望下一步的 x^{k+1} 落在可行域外，因此需要使用罚项，当落在可行域外时使罚项变得很大，以此迫使 $\argmin_{\alpha} P(x^{(k)} + \alpha d^{(k)}, \sigma)$ 解出来的 α 满足 $x^{(k+1)} = x^{(k)} + \alpha d^{(k)}$ 落在可行域内。 $P(x, \sigma)$ 如下所示定义：

$$\begin{aligned} P(x, \sigma) &= f(x) + \sigma \sum_{i=1}^m |c_i(x)_-| \\ c_i(x)_- &= \begin{cases} c_i(x), i \in \epsilon \\ \min(0, c_i(x)), i \in I \end{cases} \end{aligned} \quad (10)$$

整个算法流程如下所示：

1. 给定 $x^{(0)}, \lambda^{(0)}, \sigma > 0, \rho \in (0, 1), \epsilon \geq 0$ ，令 $k = 0$ 。
2. 利用 $x^{(k)}, \lambda^{(k)}$ 求出 $W(x^{(k)}, \lambda^{(k)}), \nabla f(x^{(k)}), c(x^{(k)}), A(x^{(k)})$ 。求解子问题 (9) 得到解 $d^{(k)}$ 以及 lagrange multipliers $\bar{\lambda}^{(k)}$ ，如果此时 $\|d^{(k)}\| \leq \epsilon$ ，则停止整个过程，否则进行一维搜索：

$$\alpha_k = \argmin_{\alpha} P(x^{(k)} + \alpha d^{(k)}, \sigma) \quad (11)$$

3. 令 $x^{(k+1)} = x^{(k)} + \alpha_k d^{(k)}, \lambda^{(k+1)} = \lambda^{(k)} + \alpha_k (\bar{\lambda}^{(k)} - \lambda^{(k)})$ ， $k = k + 1$ ，转到 2 继续进行算法。

二、实验配置

三、对数据集的处理

四、实验过程

五、超参数测试

六、实验结论